

# Classificação de Câncer de Pele utilizando CNN

Este notebook realiza o treinamento, avaliação e visualização com Grad-CAM de um modelo baseado em **MobileNetV2** para classificação de imagens dermatológicas.

Todas as seções estão nomeadas em português para facilitar a compreensão do fluxo de trabalho.

## Importação das Bibliotecas

```
In [1]: # Instalar dependências (execute apenas se necessário)
!pip install -q pandas numpy matplotlib seaborn scikit-learn tensorflow shap op
```

```
In [2]: import os
from pathlib import Path
import glob
import numpy as np
import pandas as pd
from PIL import Image
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report, confusion_matrix
import tensorflow as tf
from tensorflow.keras.preprocessing.image import ImageDataGenerator, load_img, i
from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras.models import Model
from tensorflow.keras.layers import GlobalAveragePooling2D, Dense, Dropout
from tensorflow.keras.optimizers import Adam
import cv2
import warnings
from sklearn.utils.class_weight import compute_class_weight
import numpy as np

warnings.filterwarnings("ignore", category=UserWarning, module="keras.src.traine")

# Garantir comportamento determinístico
np.random.seed(42)

print('Imports carregados')
```

Imports carregados

## Carregamento e Preparação dos Dados

```
In [3]: # Detectar automaticamente o dataset e realizar download

def find_latest_kagglehub_dataset(base_dir_name='farjanakabirsamanta/skin-cancer
home = Path.home()
cache_base = home / '.cache' / 'kagglehub' / 'datasets'
if cache_base.exists():
```

```

candidates = list(cache_base.glob(f'**/{base_dir_name}'))
if not candidates:
    candidates = list(cache_base.glob('**/skin-cancer-dataset'))
if candidates:
    # ordenar por profundidade e escolher o primeiro mais provável
    candidates.sort(key=lambda p: (str(p).count(os.sep), p.name), reverse=True)
    return Path(candidates[0])
# fallback: procurar no diretório atual
cwd = Path.cwd()
csvs = list(cwd.glob('**/HAM10000_metadata.csv'))
if csvs:
    return csvs[0].parent
raise FileNotFoundError('Dataset HAM10000 não encontrado. Coloque o CSV e imagem na mesma pasta')

dataset_base = find_latest_kagglehub_dataset()

```

```

In [4]: # Carregar metadados e resolver caminhos das imagens
metadata_path = list(dataset_base.glob('**/HAM10000_metadata.csv'))[0]
metadata = pd.read_csv(metadata_path)

# Mapear diagnósticos
mapping = {
    'akiec': 'Queratose actínica',
    'bcc': 'Carcinoma basocelular',
    'bkl': 'Lesão benigna tipo queratose', # Ou: Queratose seborreica (dependendo da localização)
    'df': 'Dermatofibroma',
    'mel': 'Melanoma',
    'nv': 'Nevo melanocítico', # Popularmente 'pinta'
    'vasc': 'Lesão vascular'
}
metadata['diagnosis'] = metadata['dx'].map(mapping)

## Renomear Colunas
# Mapeamento do nome da coluna original (inglês/código) para o nome desejado (Pt)
column_rename_map = {
    'lesion_id': 'id_lesao',
    'image_id': 'image_id',
    'dx': 'codigo_diagnostico', # O código de diagnóstico original (ex: nv, mel)
    'dx_type': 'tipo_diagnostico',
    'age': 'idade',
    'sex': 'sexo',
    'localization': 'localizacao',
    'diagnosis': 'diagnostico', # O diagnóstico mapeado por extenso
    'image_path': 'image_path'
}

# Aplicar o renomeio
metadata = metadata.rename(columns=column_rename_map)

# localizar pasta de imagens: procurar pastas com muitas imagens
image_folders = [p for p in dataset_base.glob('**/*') if p.is_dir()]
best = None
best_count = 0
for p in image_folders:
    count = len(list(p.glob('.jpg')))
    if count > best_count:
        best = p
        best_count = count
if best is None or best_count == 0:
    raise FileNotFoundError('Pasta de imagens não encontrada no dataset base: ')

```

```

images_root = best

# construir caminho completo

def resolve_image_path(image_id, images_root):
    for ext in ('.jpg', '.jpeg', '.png'):
        candidate = images_root / f"{image_id}{ext}"
        if candidate.exists():
            return str(candidate)
    # procurar recursivamente
    found = list(images_root.rglob(f"{image_id}.*"))
    return str(found[0]) if found else None

metadata['image_path'] = metadata['image_id'].apply(lambda x: resolve_image_path)
metadata = metadata[metadata['image_path'].notnull()].reset_index(drop=True)

# Mapeamento dos valores de sexo
sexo_mapping = {
    'male': 'masculino',
    'female': 'feminino',
    'unknown': 'desconhecido' # Incluindo o valor 'unknown' (desconhecido) por s
}

# Aplicar o mapeamento de tradução à coluna 'sexo'
metadata['sexo'] = metadata['sexo'].replace(sexo_mapping)

print('Registros carregados:', len(metadata))
metadata.head()

```

Registros carregados: 10015

Out[4]:

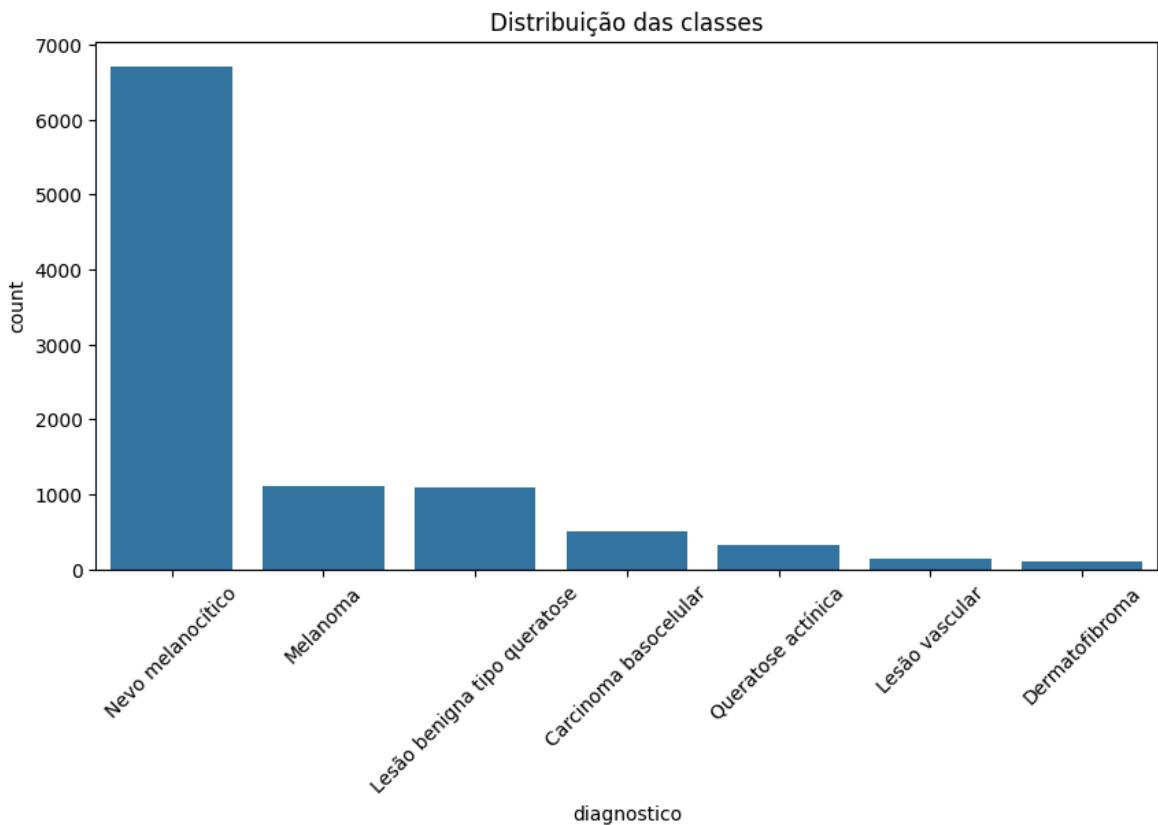
	<b>id_lesao</b>	<b>image_id</b>	<b>codigo_diagnostico</b>	<b>tipo_diagnostico</b>	<b>idade</b>	<b>sexo</b>
<b>0</b>	HAM_0000118	ISIC_0027419		bkl	histo	80.0
<b>1</b>	HAM_0000118	ISIC_0025030		bkl	histo	80.0
<b>2</b>	HAM_0002730	ISIC_0026769		bkl	histo	80.0
<b>3</b>	HAM_0002730	ISIC_0025661		bkl	histo	80.0
<b>4</b>	HAM_0001466	ISIC_0031633		bkl	histo	75.0

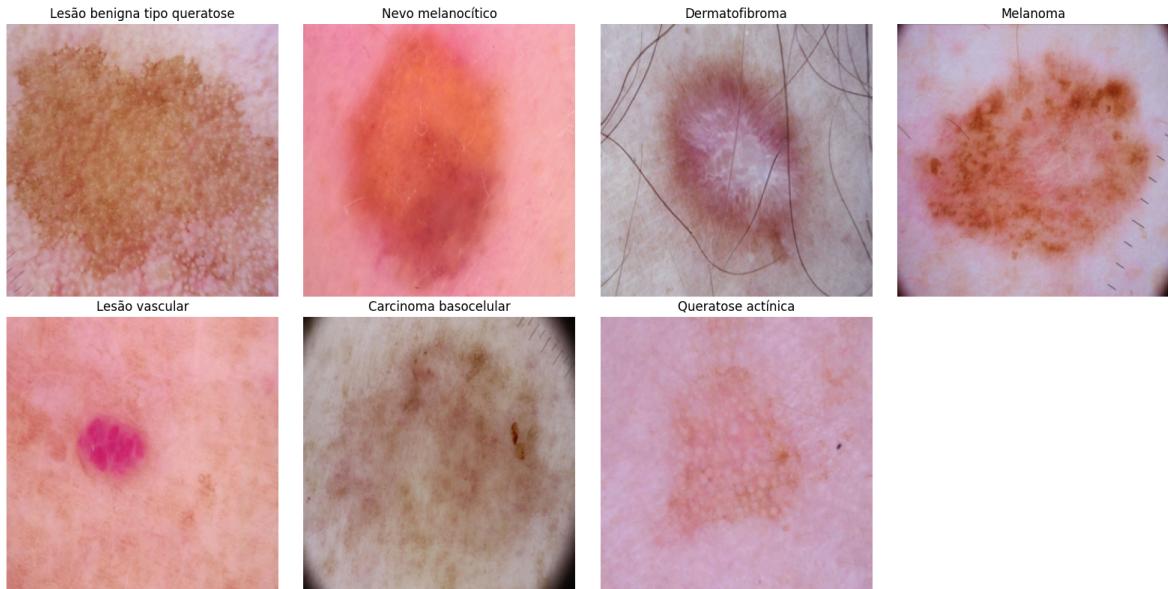


## 🔍 Exploração de Dados

```
In [5]: plt.figure(figsize=(10,5))
sns.countplot(data=metadata, x='diagnostico', order=metadata['diagnostico'].values
plt.xticks(rotation=45)
plt.title('Distribuição das classes')
plt.show()

unique_labels = metadata['diagnostico'].unique()
cols = 4
rows = (len(unique_labels) + cols - 1) // cols
plt.figure(figsize=(4*cols, 4*rows))
for i, label in enumerate(unique_labels):
    subset = metadata[metadata['diagnostico'] == label]
    if subset.empty:
        continue
    sample_row = subset.sample(1, random_state=42).iloc[0]
    img = Image.open(sample_row['image_path']).convert('RGB')
    plt.subplot(rows, cols, i+1)
    plt.imshow(img.resize((256,256)))
    plt.title(label)
    plt.axis('off')
plt.tight_layout()
```





## 🧠 Criação e Treinamento do Modelo

```
In [6]: le = LabelEncoder()
metadata['label'] = le.fit_transform(metadata['diagnostico'])
train_df, temp_df = train_test_split(metadata, stratify=metadata['label'], test_size=0.2)
test_val_df, test_df = train_test_split(temp_df, stratify=temp_df['label'], test_size=0.5)

IMG_SIZE = (224,224)
BATCH_SIZE = 32

train_datagen = ImageDataGenerator(rescale=1./255, rotation_range=20, width_shift_range=0.2, height_shift_range=0.2, shear_range=0.2, zoom_range=0.2, horizontal_flip=True, fill_mode='nearest')
val_datagen = ImageDataGenerator(rescale=1./255)

train_gen = train_datagen.flow_from_dataframe(train_df, x_col='image_path', y_col='label', class_mode='categorical', target_size=IMG_SIZE)
val_gen = val_datagen.flow_from_dataframe(val_df, x_col='image_path', y_col='label', class_mode='categorical', target_size=IMG_SIZE)
test_gen = val_datagen.flow_from_dataframe(test_df, x_col='image_path', y_col='label', class_mode='categorical', target_size=IMG_SIZE)
```

Found 7511 validated image filenames belonging to 7 classes.

Found 1252 validated image filenames belonging to 7 classes.

Found 1252 validated image filenames belonging to 7 classes.

```
In [7]: base = MobileNetV2(weights='imagenet', include_top=False, input_shape=(IMG_SIZE[0], IMG_SIZE[1], 3))
for layer in base.layers:
    layer.trainable = False

x = GlobalAveragePooling2D()(base.output)
x = Dropout(0.3)(x)
num_classes = len(train_gen.class_indices)
outputs = Dense(num_classes, activation='softmax')(x)
model = Model(inputs=base.input, outputs=outputs)
model.compile(optimizer=Adam(1e-4), loss='categorical_crossentropy', metrics=['accuracy'])
#model.summary()
```

```
In [8]: ### TREINANDO EPOCHS
```

```
# Obtém o nome das classes do gerador de treino
classes = list(train_gen.class_indices.keys())

# Exibe o número de amostras de validação por classe (útil para verificar balanceamento)
val_counts = pd.Series(val_gen.classes).value_counts().reindex(range(len(classes)))
```

```

val_counts.index = classes
print("Distribuição das classes no conjunto de validação:\n")
print(val_counts)

# Calcula pesos de classe para lidar com desbalanceamento
class_weights = compute_class_weight(
    class_weight='balanced',
    classes=np.unique(train_gen.classes),
    y=train_gen.classes
)

# Converte o resultado em dicionário no formato aceito pelo Keras
class_weights = dict(enumerate(class_weights))
print("\nPesos de classe calculados:", class_weights)

# Treinamento do modelo
EPOCHS = 50
history = model.fit(
    train_gen,
    validation_data=val_gen,
    epochs=EPOCHS,
    class_weight=class_weights,
    verbose=0 # mostra o progresso do treinamento
)

```

Distribuição das classes no conjunto de validação:

Carcinoma basocelular	64
Dermatofibroma	15
Lesão benigna tipo queratose	137
Lesão vascular	18
Melanoma	139
Nevo melanocítico	838
Queratose actínica	41

Name: count, dtype: int64

Pesos de classe calculados: {0: np.float64(2.787012987012987), 1: np.float64(12.476744186046512), 2: np.float64(1.3021844660194175), 3: np.float64(10.02803738317757), 4: np.float64(1.2850299401197605), 5: np.float64(0.21336249751441638), 6: np.float64(4.3795918367346935)}

## 📘 Avaliação

```

In [9]: preds = model.predict(test_gen)
y_pred = np.argmax(preds, axis=1)
y_true = test_gen.classes

print(classification_report(
    y_true,
    y_pred,
    target_names=list(train_gen.class_indices.keys()),
    zero_division=0
))

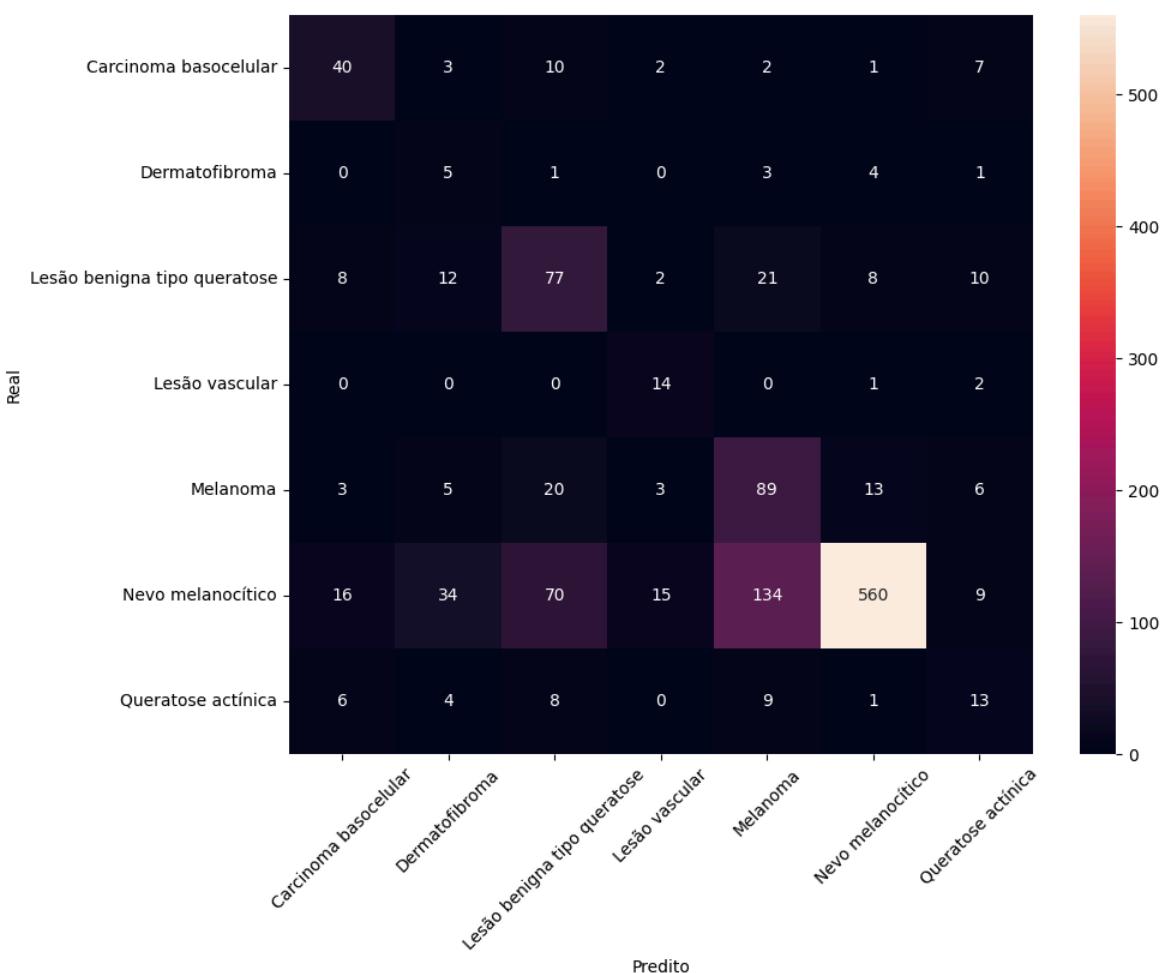
cm = confusion_matrix(y_true, y_pred)
plt.figure(figsize=(10,8))
ax = sns.heatmap(cm, annot=True, fmt='d', xticklabels=list(train_gen.class_indices.keys()),
                  yticklabels=list(train_gen.class_indices.keys()))
ax.set_xlabel('Predito')
ax.set_ylabel('Real')

```

```
plt.xticks(rotation=45)
plt.yticks(rotation=0)
plt.show()
```

40/40 ━━━━━━━━ 8s 178ms/step

		precision	recall	f1-score	support
	Carcinoma basocelular	0.55	0.62	0.58	65
	Dermatofibroma	0.08	0.36	0.13	14
Lesão benigna tipo queratose		0.41	0.56	0.48	138
	Lesão vascular	0.39	0.82	0.53	17
	Melanoma	0.34	0.64	0.45	139
	Nevo melanocítico	0.95	0.67	0.79	838
	Queratose actínica	0.27	0.32	0.29	41
	accuracy			0.64	1252
	macro avg	0.43	0.57	0.46	1252
	weighted avg	0.76	0.64	0.68	1252



## 🔥 Funções Grad-CAM

In [26]: `### 🔍 Função para encontrar a última camada convolucional`

```
def encontrar_ultima_conv(model):
    """
```

Encontra automaticamente o nome da última camada convolucional (Conv2D, DepthwiseConv2D ou SeparableConv2D), mesmo em modelos aninhados. Retorna o nome da camada ou None se não encontrar.

```
"""
```

```
ultima_conv = None
```

```

def procurar_camadas(m):
    nonlocal ultima_conv
    for layer in m.layers:
        # Se for uma subcamada (ex: bloco dentro de EfficientNet)
        if hasattr(layer, 'layers') and len(layer.layers) > 0:
            procurar_camadas(layer)
        # Verifica se é uma camada convolucional
        if isinstance(layer, (tf.keras.layers.Conv2D,
                              tf.keras.layers.DepthwiseConv2D,
                              tf.keras.layers.SeparableConv2D)):
            ultima_conv = layer.name

procurar_camadas(model)

if ultima_conv is None:
    print("⚠️ Nenhuma camada convolucional encontrada. Modelo pode não ser")
else:
    print(f"✅ Última camada convolucional encontrada: {ultima_conv}")

return ultima_conv

ultima_conv = encontrar_ultima_conv(model)
print(ultima_conv)

def gerar_gradcam_heatmap(model, img_array, last_conv_layer_name, pred_index=None):
    grad_model = tf.keras.models.Model(model.input, [model.get_layer(last_conv_layer_name).output])
    with tf.GradientTape() as tape:
        conv_outputs, predictions = grad_model(img_array)
        if pred_index is None:
            pred_index = tf.argmax(predictions[0])
        class_channel = predictions[:, pred_index]
        grads = tape.gradient(class_channel, conv_outputs)
        pooled_grads = tf.reduce_mean(grads, axis=(0,1,2))

        conv_outputs = conv_outputs[0].numpy()
        pooled_grads = pooled_grads.numpy()
        for i in range(pooled_grads.shape[-1]):
            conv_outputs[:, :, i] *= pooled_grads[i]
        heatmap = np.mean(conv_outputs, axis=-1)
        heatmap = np.maximum(heatmap, 0)
        heatmap /= (heatmap.max() + 1e-8)
        heatmap = cv2.resize(heatmap, (IMG_SIZE[1], IMG_SIZE[0]))
        heatmap = np.uint8(255 * heatmap)
        heatmap = cv2.applyColorMap(heatmap, cv2.COLORMAP_JET)
    return heatmap

def gerar_mapa_gradcam(model, imagem_array, nome_camada_conv):
    grad_model = tf.keras.models.Model(
        inputs=model.inputs,
        outputs=[model.get_layer(nome_camada_conv).output, model.output]
    )

    with tf.GradientTape() as tape:
        conv_output, pred = grad_model(imagem_array)
        classe_pred = tf.argmax(pred[0])
        loss = pred[:, classe_pred]

        grads = tape.gradient(loss, conv_output)[0]
        pesos = tf.reduce_mean(grads, axis=(0,1))

```

```
gradcam = tf.reduce_sum(tf.multiply(pesos, conv_output[0]), axis=-1)

heatmap = np.maximum(gradcam, 0) / (tf.reduce_max(gradcam) + 1e-8)
heatmap = cv2.resize(heatmap.numpy(), (224, 224))
heatmap = np.uint8(255 * heatmap)
heatmap = cv2.applyColorMap(heatmap, cv2.COLORMAP_JET)
return heatmap
```

Última camada convolucional encontrada: Conv\_1  
Conv\_1

## Visualização Grad-CAM em Lote

```
In [27]: def gradcam_em_lote(model, df, ultima_conv, IMG_SIZE=(224,224), num_imagens=6):

    exemplos = df.sample(num_imagens, random_state=42).reset_index(drop=True)
    plt.figure(figsize=(10, num_imagens * 3))

    for i, row in exemplos.iterrows():
        # 🔘 Carrega e normaliza imagem
        img_path = row['image_path']
        imagem = load_img(img_path, target_size=IMG_SIZE)
        imagem_arr = img_to_array(imagem) / 255.0
        entrada = tf.convert_to_tensor(np.expand_dims(imagem_arr, axis=0), dtype

        # 🔘 Gera mapa Grad-CAM
        mapa = gerar_mapa_gradcam(model, entrada, ultima_conv)

        # 🔘 Normaliza o mapa de calor para sobrepor
        mapa = cv2.resize(mapa, (IMG_SIZE[1], IMG_SIZE[0]))
        mapa = np.uint8(255 * mapa)
        mapa = cv2.applyColorMap(mapa, cv2.COLORMAP_JET)
        sobreposta = cv2.addWeighted(np.uint8(imagem_arr*255), 0.6, mapa, 0.4, 0

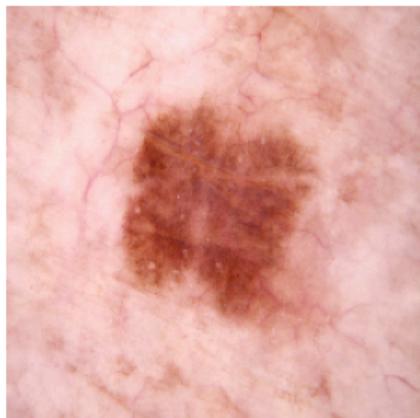
        # 🔘 Mostra imagem original
        plt.subplot(num_imagens, 2, 2*i + 1)
        plt.imshow(imagem)
        plt.title(f'Imagen Original: {row["diagnostico"]}')
        plt.axis('off')

        # 🔘 Mostra Grad-CAM
        plt.subplot(num_imagens, 2, 2*i + 2)
        plt.imshow(cv2.cvtColor(sobreposta, cv2.COLOR_BGR2RGB))
        plt.title('Mapa Grad-CAM')
        plt.axis('off')

    plt.tight_layout()
    plt.show()
```

```
In [28]: gradcam_em_lote(model, test_df, ultima_conv, num_imagens=6)
```

Imagen Original: Queratose actínica



Mapa Grad-CAM

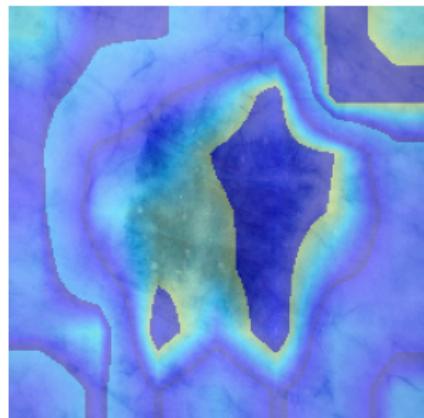
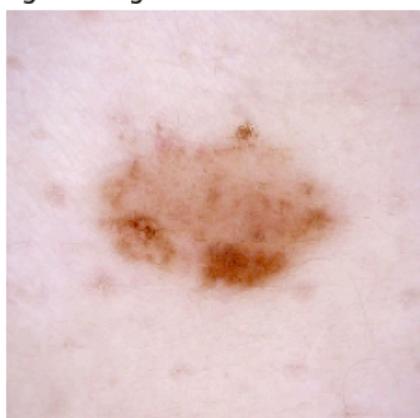


Imagen Original: Nevo melanocítico



Mapa Grad-CAM

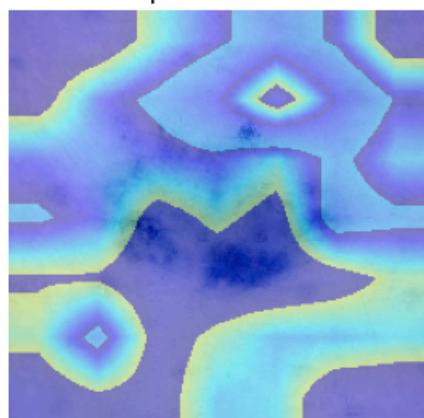


Imagen Original: Carcinoma basocelular



Mapa Grad-CAM

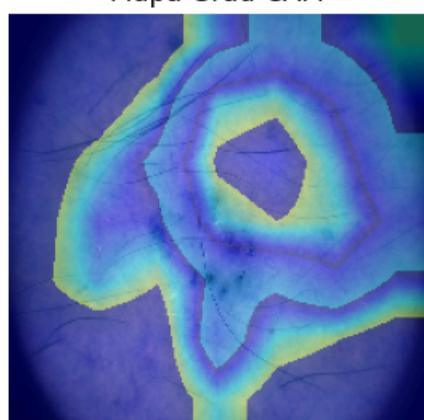


Imagen Original: Nevo melanocítico



Mapa Grad-CAM

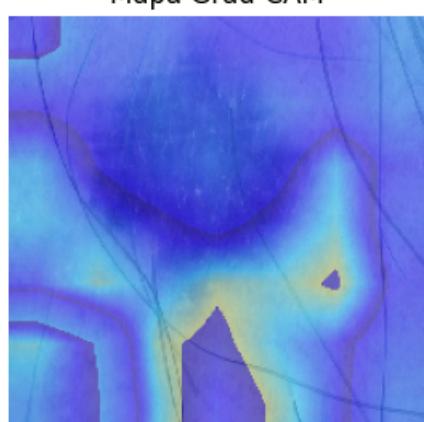


Imagen Original: Nevo melanocítico

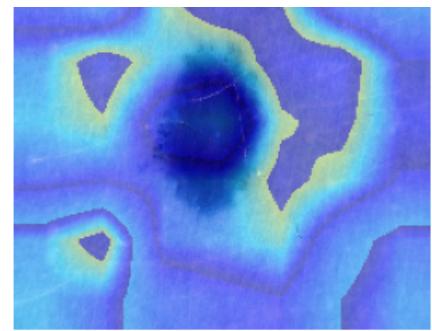


Mapa Grad-CAM

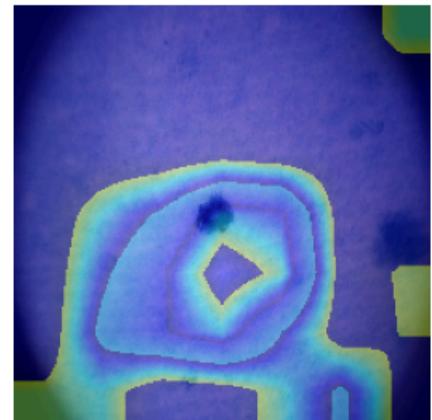




Imagen Original: Nevo melanocítico



Mapa Grad-CAM



## Salvamento do Modelo (formato moderno .keras)

```
In [29]: model.save('modelo_cancer_pele.keras')
print('Modelo salvo com sucesso!')
```

Modelo salvo com sucesso!